



ICMC - INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO  
*USP CÂMPUS SÃO CARLOS*  
BACHARELADO EM CIÊNCIAS DE DADOS

Gustavo Silva Lima  
NUSP:16907230

**CURADORIA DE DADOS DE SEQUENCIAMENTO: REMOÇÃO DE  
ADAPTADORES E OTIMIZAÇÃO DO CONTROLE DE QUALIDADE NA  
AMOSTRA SRR2079546**

Professor orientador: Prof.: Dr. Ricardo Cerri

São Carlos  
2026

## **RESUMO**

### **SUMÁRIO**

#### **1 - INTRODUÇÃO**

#### **2 - MATERIAIS E MÉTODOS**

##### **2.1 - OBTENÇÃO DOS DADOS BRUTOS**

##### **2.2 - DIAGNÓSTICO INICIAL DE QUALIDADE (FastQC)**

##### **2.3-CONSTRUÇÃO DO ARQUIVO DE ADAPTADORES**

##### **2.4 - CORTE DE ADAPTADORES E QUALIDADE**

##### **2.5 - ANÁLISE DE RESÍDUOS E REAVALIAÇÃO**

#### **3- QUESTIONÁRIO ANALÍTICO**

##### **3.1 - SUCESSO DO TRIMMING**

##### **3.2 - DECISÃO DE PARÂMETROS**

##### **3.3 - ANÁLISE CRÍTICA SOBRE RIGOR EXCESSIVO**

#### **4- CONCLUSÃO**

## 1. INTRODUÇÃO

O sequenciamento de nova geração (NGS) exige a curadoria rigorosa dos dados brutos para garantir a precisão das análises biológicas subsequentes. Esse pré-processamento atua em duas frentes essenciais: a eliminação de bases de baixa qualidade (que induzem erros analíticos) e a excisão de adaptadores artificiais (fragmentos da preparação da biblioteca que contaminam os resultados). Diferentemente da atividade padrão em sala — que omitiu a filtragem de adaptadores para fins didáticos —, este relatório reproduz um fluxo real de bioinformática. Utilizando a amostra do projeto SRP059581 (Ruggiero et al., 2015; técnica TCR-LA-MC PCR), implementou-se a curadoria completa das leituras, assegurando a remoção do adaptador Illumina previamente mapeado e avaliando o impacto prático de diferentes limiares de qualidade

## 2. MATERIAIS E MÉTODOS

### 2.1. OBTENÇÃO DOS DADOS BRUTOS

O identificador de projeto SRP059581 foi buscado na base SRA do NCBI. Dentro da lista de experimentos, foi localizado o experimento SRX1074311 ("TCRLAMC PCR Sezary Limiting dilution PB cDNA 100ng Beta chain"), correspondente à amostra de 100 ng solicitada no desafio. A corrida associada a esse experimento é a SRR2079546.

☐ [TCRLAMC PCR Sezary Limiting dilution PB cDNA 100ng Beta chain](#)  
15. 1 ILLUMINA (Illumina MiSeq) run: 324,292 spots, 47M bases, 31.7Mb downloads  
Accession: SRX1074311

An official website of the United States government [Here's how you know](#)

**NIH** National Library of Medicine  
National Center for Biotechnology Information

Log in

SRA   [Advanced](#) [Help](#)

**!** Submissions to SRA will need to meet SRA Data Submission Standards designed to improve data quality, usability, and submission processing. Read our recent [NCBI Insights blog](#) for more details.

Full  Send to:

**SRX1074311: TCRLAMC PCR Sezary Limiting dilution PB cDNA 100ng Beta chain**  
1 ILLUMINA (Illumina MiSeq) run: 324,292 spots, 47M bases, 31.7Mb downloads

**Submitted by:** DKFZ

**Study:** TCR ligation anchored-magnetically captured PCR (TCR-LA-MC PCR) for TCR a-and  $\beta$ -chain diversity dissection  
[PRJNA287162](#) • [SRP059581](#) • [All experiments](#) • [All runs](#)  
[show Abstract](#)

**Sample:** Sezary\_PB\_cDNA\_100ng  
[SAMN03797460](#) • [SRS973394](#) • [All experiments](#) • [All runs](#)  
**Organism:** [Homo sapiens](#)

**Library:**  
**Instrument:** Illumina MiSeq  
**Strategy:** AMPLICON  
**Source:** TRANSCRIPTOMIC  
**Selection:** PCR  
**Layout:** SINGLE

**Runs:** 1 run, 324,292 spots, 47M bases, [31.7Mb](#)

| Run                        | # of Spots | # of Bases | Size   | Published  |
|----------------------------|------------|------------|--------|------------|
| <a href="#">SRR2079546</a> | 324,292    | 47M        | 31.7Mb | 2015-07-02 |

ID: 1560086

**Related information**  
[BioProject](#)  
[BioSample](#)  
[Taxonomy](#)

**Recent activity**  
[Turn Off](#) [Clear](#)

SRA

SRA

[See more...](#)


O download e a conversão foram realizados via SRA Toolkit:

```
C:\Users\Lenovo Thinkpad E14\Downloads\sratoolkit.3.4.1-win64\sratoolkit.3.4.1-win64\bin>prefetch SRR2079546
2026-09-21T19:03:35 prefetch.3.4.1: 1) Resolving 'SRR2079546'...
2026-09-21T19:03:37 prefetch.3.4.1: Current preference is set to retrieve SRA Normalized Format files with full base quality scores
2026-09-21T19:03:38 prefetch.3.4.1: 1) Downloading 'SRR2079546'...
2026-09-21T19:03:38 prefetch.3.4.1: SRA Normalized Format file is being retrieved
2026-09-21T19:03:38 prefetch.3.4.1: Downloading via HTTPS...
2026-09-21T19:03:43 prefetch.3.4.1: HTTPS download succeed
2026-09-21T19:03:43 prefetch.3.4.1: verifying 'SRR2079546'...
2026-09-21T19:03:43 prefetch.3.4.1: 'SRR2079546' is valid: 33270119 bytes were streamed from 33263481
2026-09-21T19:03:43 prefetch.3.4.1: 1) 'SRR2079546' was downloaded successfully
2026-09-21T19:03:43 prefetch.3.4.1: 1) Resolving 'SRR2079546's dependencies...
2026-09-21T19:03:43 prefetch.3.4.1: 'SRR2079546' has 0 unresolved dependencies
C:\Users\Lenovo Thinkpad E14\Downloads\sratoolkit.3.4.1-win64\sratoolkit.3.4.1-win64\bin>
```

## 2.2. DIAGNÓSTICO INICIAL DE QUALIDADE (FastQC)

Após a conversão, o arquivo SRR2079546.fastq foi submetido ao FastQC, o relatório resultante (SRR2079546\_fastqc.html) foi aberto no navegador para

inspeção. Página inicial do relatório :



| Basic sequence stats              |                         |
|-----------------------------------|-------------------------|
| Measure                           | Value                   |
| Filename                          | SRR2079546.fastq        |
| File type                         | Conventional base calls |
| Encoding                          | Sanger / Illumina 1.9   |
| Total Sequences                   | 324292                  |
| Total Bases                       | 47 Mbp                  |
| Sequences flagged as poor quality | 0                       |
| Sequence length                   | 55-450                  |
| %GC                               | 55                      |

A avaliação inicial dos dados brutos indicou o uso de adaptadores customizados. O módulo "Overrepresented sequences" revelou múltiplas seqüências abundantes não reconhecidas pela base padrão ("No Hit"), com a principal (ATCGTCAGTGCGGGTGGGAACACCTTGTTTCAGGTCCTCGAGCACTGTCAG) a representar 17,7% das leituras, seguida por outra similar com 16,9%. Em contraste, o módulo "Adapter Content" não acusou contaminação significativa por adaptadores universais da Illumina, registrando valores residuais abaixo de 5%. Essa dinâmica confirmou que a contaminação provinha do protocolo específico, permitindo extrair a seqüência exata para compor o arquivo `manual adapters.fa` e direcionar o corte preciso (*trimming*) executado pelo utilitário

## FastQC Report

### Summary


- ✓ [Basic Statistics](#)
- ✗ [Per base sequence quality](#)
- ✓ [Per sequence quality scores](#)
- ✗ [Per base sequence content](#)
- ✗ [Per sequence GC content](#)
- ✓ [Per base N content](#)
- ⚠ [Sequence Length Distribution](#)
- ✗ [Sequence Duplication Levels](#)
- ✗ [Overrepresented sequences](#)
- ✓ [Adapter Content](#)

### ✗ Overrepresented sequences

| Sequence                                             | Count | Percentage          | Possible Source |
|------------------------------------------------------|-------|---------------------|-----------------|
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCGAGCACTGTGAG  | 57552 | 17.74696878122186   | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTGTGAG   | 55015 | 16.96464914336462   | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTAGGATGGAGAG    | 34739 | 10.712259321845744  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCTACAACGTGTGAG | 33373 | 10.291034006389303  | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCTACAACGTGTGAG  | 24223 | 7.469502793778447   | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCCAGGCACTGT    | 22640 | 6.9813624757934205  | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCCAGGCACTGT     | 18668 | 5.756540401860052   | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTAGGATGGAGAG     | 14050 | 4.332515140675687   | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCTACAACGGTTAA  | 4885  | 1.5063584670605503  | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCTCGCCCATCCC    | 4151  | 1.2800192419177778  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCTCGCCCATCCC   | 3884  | 1.1976860360415922  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCAAGACAGAGAG   | 3825  | 1.1794925560914238  | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCTACAACGGTTAA   | 2020  | 0.6228954152430526  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCGAGCACCAGGAG  | 1814  | 0.5593724174509392  | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCGAGCACCAGGAG   | 1782  | 0.5495047673084751  | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCAAGACAGAGAG    | 1514  | 0.46686319736533743 | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTAGCACGGTGAG     | 1313  | 0.40488201990798417 | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTGTGAT   | 1217  | 0.3752790694805916  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCGAGCACTGTGAT  | 1159  | 0.3573939535973752  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCTAGCACGGTGAG  | 1158  | 0.35708558953042324 | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTGTGAG  | 864   | 0.26642655384653335 | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCTGGAAGGGGAAG  | 769   | 0.23713196748609278 | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCTGGAAGGGGAAG   | 742   | 0.22880613767838864 | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCTGTGACCGTGAG   | 614   | 0.1893355371085318  | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTTAGCG   | 587   | 0.18100970730882763 | No Hit          |
| CGATGCGATGCGGGTGGGAACACGTTTTTCAGGTCCTCCAGCACTGAGAG   | 521   | 0.16065767888199525 | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCGAGCACTTAGCG  | 517   | 0.15942422261418723 | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCCAGCACTGAGAG  | 498   | 0.1535653053420991  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAGGTCCTCTGTGACCGTGAG  | 485   | 0.14955657247172302 | No Hit          |
| CGATGCGATGCGGGTGGGAACACCTTGTTCAGGTCCTCTAGGATGGAGAG   | 359   | 0.11070270003577024 | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACGTTTTTCAGGTCCTCTACAACGTGTGAG | 331   | 0.10206850616111406 | No Hit          |

## 2.3. CONSTRUÇÃO DO ARQUIVO DE ADAPTADORES

A sequência identificada foi salva no formato FASTA exigido pelo fastq-mcf, no arquivo adapters.fa:



## 2.4. CORTE DE ADAPTADORES E QUALIDADE (fastq-mcf)

A etapa de remoção de adaptadores e controle de qualidade foi realizada utilizando o programa `fastq-mcf`, aplicando o arquivo FASTA customizado (`adapters.fa`) aos dados brutos da amostra. Com o intuito de estabelecer a estratégia de curadoria ideal, o processo foi executado em três cenários independentes, isolando o impacto de diferentes níveis de rigor técnico:

- **Cenário Padrão (-q 20):** Aplicação de um filtro de qualidade basal, realizando o corte nas extremidades das leituras sempre que a qualidade Phred for inferior a 20.
- **Cenário Intermediário (-q 25 -x 10):** Elevação do limiar de qualidade Phred mínima para 25, aliada ao parâmetro `-x 10` para ajustar a tolerância e o rigor do corte (skew/truncamento) nas extremidades.
- **Cenário Rigoroso (-q 30 -l 50):** Exigência de uma alta qualidade Phred (mínima de 30) associada a um filtro de comprimento de leitura (`-l 50`), descartando integralmente qualquer sequência que, após a limpeza, detenha um tamanho inferior a 50 pares de bases.

A execução destas três abordagens gerou arquivos FASTQ independentes, preparados exclusivamente para a fase subsequente de reavaliação.

```

Within-read Skew: Position 67 from the start of reads is skewed!
Within-read Skew: Position 68 from the start of reads is skewed!
Within-read Skew: Position 76 from the start of reads is skewed!
Within-read Skew: Position 78 from the start of reads is skewed!
Trim 'start': 40 from SRR2079546.fastq
Threshold used: 751 out of 300000
(ATCGTCAGTGCGGGTGGGAACACCTTGTTTCAGGTCCTCGAGCACTGTCA): counted 184578 at the 'start' of 'SRR2079546.fastq',
clip set to 1
Files: 1
Total reads: 324292
Too short after clip: 9418
Clipped 'start' reads: Count: 179215, Mean: 26.92, Sd: 23.92
Trimmed 53803 reads by an average of 1.77 bases on quality < 20

```

Problemas Saída Console de Depuração **Terminal** Portas

```

Within-read Skew: Position 76 from the start of reads is skewed!
Within-read Skew: Position 78 from the start of reads is skewed!
Trim 'start': 40 from SRR2079546.fastq
Threshold used: 751 out of 300000
(ATCGTCAGTGCGGGTGGGAACACCTTGTTTCAGGTCCTCGAGCACTGTCA): counted 184578 at the 'start' of 'SRR2079546.fastq',
clip set to 1
Files: 1
Total reads: 324292
Too short after clip: 9420
Clipped 'start' reads: Count: 179215, Mean: 26.92, Sd: 23.92
Trimmed 56523 reads by an average of 1.93 bases on quality < 25

```

```

Within-read Skew: Position 76 from the start of reads is skewed!
Within-read Skew: Position 78 from the start of reads is skewed!
Trim 'start': 40 from SRR2079546.fastq
Threshold used: 751 out of 300000
(ATCGTCAGTGCGGGTGGGAACACCTTGTTTCAGGTCCTCGAGCACTGTCA): counted 184578 at the 'start' of 'SRR2079546.fastq',
clip set to 1
Files: 1
Total reads: 324292
Too short after clip: 92107
Clipped 'start' reads: Count: 126045, Mean: 25.98, Sd: 23.98
Trimmed 64602 reads by an average of 3.80 bases on quality < 30

```

-  SRR2079546\_Q20\_clean.fastq
-  SRR2079546\_Q25\_X10\_clean.fastq
-  SRR2079546\_Q30\_L50\_clean.fastq
-  SRR2079546.fastq

## 2.5. ANÁLISE DE RESÍDUOS E REAVALIAÇÃO


A reavaliação da qualidade dos dados processados, conduzida através da sobreposição dos relatórios FastQC (antes e após a curadoria), validou a eficácia da etapa de limpeza e evidenciou o impacto direto das diferentes métricas de filtragem.

A sequência adaptadora customizada, que inicialmente dominava o painel de contaminação (representando mais de 30% das leituras somando as suas variantes no módulo *Overrepresented sequences*), foi integralmente erradicada em todos os cenários testados. No que tange à qualidade das bases (*Per base sequence quality*), o ficheiro bruto apresentava um declínio acentuado no índice Phred no terço final das sequências. Os arquivos processados exibiram uma correção estrutural clara: as extremidades defeituosas foram aparadas, mantendo a distribuição dos dados de forma consistente na zona de alta confiança (Phred > 28).


O impacto mais sensível, no entanto, recaiu sobre o rendimento e a integridade física dos dados (*Basic Statistics* e *Sequence Length Distribution*). A aplicação do limiar mais estrito (-q 30 -l 50) resultou numa penalização expressiva na retenção: o comprimento máximo das leituras sofreu uma redução severa (de aproximadamente 410 pb para 184 pb) e o volume total de sequências úteis caiu drasticamente. Esta dinâmica ilustra o compromisso inevitável (*trade-off*) em pipelines de NGS: a imposição de um rigor absoluto na qualidade de cada base resulta invariavelmente numa perda massiva de profundidade de cobertura do sequenciamento.

**ANTES:**

## ❌ Per base sequence quality





## ⚠️ Sequence Length Distribution



## Overrepresented sequences

| Sequence                                            | Count | Percentage          | Possible Source |
|-----------------------------------------------------|-------|---------------------|-----------------|
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCGAGCACTGTCAG | 57552 | 17.74696878122186   | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTGTCAG | 55015 | 16.96464914336462   | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCTAGGATGGAGAG | 34739 | 10.712259321845744  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCTACAACGTGAG  | 33373 | 10.291034006389303  | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTACAACGTGAG  | 24223 | 7.469502793778447   | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCTCCAGGCACTGT | 22640 | 6.9813624757934205  | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTCCAGGCACTGT | 18668 | 5.756540401860052   | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTAGGATGGAGAG | 14050 | 4.332515140675687   | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCTACAACGGTTAA | 4885  | 1.5063584670605503  | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTCTGCCATCCC  | 4151  | 1.2800192419177778  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCTCTGCCATCCC  | 3884  | 1.1976860360415922  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCCAAGACAGAGAG | 3825  | 1.1794925560914238  | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTACAACGGTTAA | 2020  | 0.6228954152430526  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCGAGCACCAGGAG | 1814  | 0.5593724174509392  | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCGAGCACCAGGAG | 1782  | 0.5495047673084751  | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCCAAGACAGAGAG | 1514  | 0.46686319736533743 | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTAGCACGGTGAG | 1313  | 0.40488201990798417 | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTGTCAT | 1217  | 0.3752790694805916  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCGAGCACTGTCAT | 1159  | 0.3573939535973752  | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCTAGCACGGTGAG | 1158  | 0.35708558953042324 | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTGTCAG | 864   | 0.26642655384653335 | No Hit          |
| ATCGTCAGTGC GGGTGGGAACACCTTGTTCAAGTCCTCTGGAAGGGAAG  | 769   | 0.23713196748609278 | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTGGAAGGGAAG  | 742   | 0.22880613767838864 | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCTGTGACCGTGAG | 614   | 0.1893355371085318  | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCGAGCACTTAGCG | 587   | 0.18100970730082763 | No Hit          |
| CGATGCGATGC GGGTGGGAACACGTTTTTCAGGTCCTCCAGCACTGAGAG | 521   | 0.16065767888199525 | No Hit          |

DEPOIS:



| Sequence                                           | Count | Percentage          | Possible Source |
|----------------------------------------------------|-------|---------------------|-----------------|
| CAGGCACTGTCTCAGGATGTTTGTAGCTCCTTAGAGCTGGATGCTTTG   | 34833 | 15.002261127979843  | No Hit          |
| GCACTGTCAAGCCGGTGCCTGGGCCAAAATACTGCGTATCTGTTAATGTT | 32376 | 13.944053233413012  | No Hit          |
| GCCGGGTGCTGGGCCAAAATACTGCGTATCTGTTAATGTTCTGCTAAG   | 31357 | 13.505179059801451  | No Hit          |
| GGATGGAGAGTCGAGTCCCATCACAAAATGCTGGGGCTGATTGCTACAC  | 21184 | 9.12375907143011    | No Hit          |
| CAACTGTGAGTCTGGTCCCTTGTCCTCAAGAAAGCTTCAGTGTCCGCCCT | 16745 | 7.211921528091823   | No Hit          |
| GTCTGGTGCCTTGTCCTCAAGAAAGCTTCAGTGTCCGCCCTGCCCCACA  | 15781 | 6.79673536188815    | No Hit          |
| TGCCCATCCCGCCCTCTCGGAGCTCTCCGGAGCCCAACCGCCTCCTTAC  | 7260  | 3.126816977840946   | No Hit          |
| AGACAGAGAGCTGGGTTCCACTGCCAAAAACAGTTTTTCATTAGCCAC   | 2990  | 1.2877662209014362  | No Hit          |
| CAACGGTTAACCTGGTCCCCGAACCGAAGGTGTAGCCATAGTTAGCACAT | 2778  | 1.1964597196201305  | No Hit          |
| GCACTGTCAAGCCGGTGCCTGGGCCAAAATACTGCGTATCTGTGCTCACA | 2309  | 0.9944656200874303  | No Hit          |
| GCCGGGTGCTGGGCCAAAATACTGCGTATCTGTGCTCACAGCCTGGAGG  | 2245  | 0.9669013932855266  | No Hit          |
| GCACAGGAGCGCTGCTGCGCCGAAGTACTGGGTCTCTTGAGCTG       | 1647  | 0.7093481491052394  | No Hit          |
| GCCGCTGCTGGGCCGAAGTACTGGGTCTCTTGAGCTGCTGGCACAG     | 1512  | 0.6512048581949739  | No Hit          |
| CACTGTCAAGCCGGTGCCTGGGCCAAAATACTGCGTATCTGTTAATGTTT | 1495  | 0.6438831104507181  | No Hit          |
| AGACAGAGAGCTGGGTTCCACTGCCAAAAAGCAGTTTTTCATTAGCCAC  | 1423  | 0.6128733552985766  | No Hit          |
| GAAAGGAAGAGGTAATGGGCTAGGGTTGCTCTAAGAGCTGCTGGTCC    | 1331  | 0.57324977927084    | No Hit          |
| TAGCGATAGATCGCGCTTAAGTCTGCTGCTAGATCGGAAGAGCGGTT    | 1262  | 0.5435320972500377  | No Hit          |
| GGATGGAGAGTCGAGTCCCAACCAAAATGCTGGGGCTGATTGCTACAC   | 1149  | 0.49486400930292657 | No Hit          |
| GCACTGTCAAGCGATAGATCGCGCTTAAGTCTGCTGCTAGATCGGA     | 1097  | 0.47246807502637983 | No Hit          |
| AGGCACTGTCTCAGGATGTTTGTAGCTCCTTAGAGCTGGATGCTTTGT   | 1031  | 0.4440424661369167  | No Hit          |
| GGATGGAGAGTCGAGTCCCATCACAAAATGCTGGGGCTGATTAATCTCC  | 850   | 0.3660873872127829  | No Hit          |
| GCACGGTGAGCGTGTCCCTGGGCCGAAGAACTGCTCATTGTAGTAATCG  | 730   | 0.31440446195921357 | No Hit          |

### 3. RESULTADOS

#### 3.1. SUCESSO DO TRIMMING

O programa conseguiu remover a sequência com total sucesso. Ao analisar a aba "Overrepresented sequences" nos relatórios do FastQC após o processamento, a sequência adaptadora customizada (que antes representava cerca de 17,7% das leituras) e as suas variantes desapareceram completamente da lista. O módulo deixou de acusar essas sequências específicas como super-representadas, comprovando que o corte direcionado pelo utilitário `fastq-mcf`, alimentado com o arquivo `adapters.fa`, foi altamente eficaz na eliminação dessa contaminação técnica da amostra.

#### 3.2. DECISÃO DE PARÂMETROS

Durante a etapa de curadoria com o utilitário `fastq-mcf`, foram testadas três combinações distintas de parâmetros para avaliar o impacto do rigor da filtragem: um filtro basal (-q 20) que apara extremidades com qualidade Phred inferior a 20; um filtro intermediário (-q 25 -x 10) que exige qualidade mínima de 25 e aplica um recorte extra de até 10 bases; e um filtro rigoroso (-q 30 -l 50) que exige alta qualidade (Phred 30) aliada ao descarte integral de

leituras que resultem em menos de 50 pares de bases após o corte. Dentre estas abordagens, a configuração basal de -q 20 gerou o conjunto de dados mais equilibrado. Essa escolha justifica-se por atingir o ponto ótimo (*trade-off*) entre qualidade e retenção de informação: o filtro foi preciso o suficiente para erradicar a sequência adaptadora e elevar a pontuação no gráfico de qualidade (*Quality scores across all bases*) para a zona de segurança, sem sacrificar a profundidade do sequenciamento. Em contrapartida, o filtro mais rigoroso (-q 30 -l 50) demonstrou ser excessivamente agressivo, provocando uma perda massiva de sequências úteis e uma redução drástica no comprimento máximo das leituras (de aproximadamente 410 pb para 184 pb), o que poderia prejudicar severamente a viabilidade biológica da amostra para as etapas subsequentes de alinhamento.

### 3.3. ANÁLISE CRÍTICA

A aplicação de um critério extremamente rigoroso, como -q 38 (que exige 99,98% de precisão), não é recomendada porque forçaria o algoritmo a descartar a esmagadora maioria dos dados biologicamente úteis, dado que a qualidade química do sequenciamento decai naturalmente ao longo da leitura. Sob tal rigor, a métrica de *Sequence Length Distribution* exigiria um encurtamento drástico e artificial de todas as sequências, com o gráfico deslocando-se acentuadamente para a esquerda e refletindo uma queda abrupta no volume total de leituras retidas. Esse encurtamento e a perda massiva de dados impactam severamente qualquer análise de bioinformática posterior: sequências excessivamente curtas perdem a sua identidade única e tendem a alinhar em múltiplos locais do genoma de referência (*multi-mapping*), algoritmos de montagem (*assembly*) falharam devido à falta de sobreposições longas (gerando montagens fragmentadas e cheias de lacunas), e a drástica redução na profundidade de cobertura tornaria estatisticamente impossível distinguir mutações biológicas reais (SNPs) de meros erros técnicos residuais do equipamento.

## 4. Conclusão

A presente análise demonstrou a importância crítica da curadoria ativa e do controle de qualidade no processamento inicial de dados brutos de sequência de nova geração (NGS). Através da avaliação com o FastQC, foi possível ultrapassar a aparente ausência de adaptadores universais e identificar uma contaminação específica do protocolo na amostra SRR2079546, viabilizando a extração de um ficheiro de

adaptadores customizado e a sua posterior remoção direcionada. A aplicação do utilitário fastq-mcf sob diferentes níveis de rigor evidenciou que a limpeza de sequências artificiais e bases de baixa qualidade é altamente eficaz, mas exige um compromisso (*trade-off*) cauteloso. Constatou-se que a imposição de limiares de qualidade excessivamente restritivos resulta numa fragmentação severa das leituras e numa perda massiva de volume de dados, fatores que comprometem gravemente a precisão das análises a jusante, como o alinhamento e a montagem. Em contrapartida, a adoção de um filtro de qualidade basal e equilibrado (-q 20) revelou-se a estratégia ideal: garantiu a erradicação total dos contaminantes e a elevação da qualidade global das leituras para patamares seguros, preservando, em simultâneo, a integridade estrutural, o comprimento e a profundidade biológica da amostra para as etapas seguintes do *pipeline* de bioinformática.